INFORMATICA · DATI

Big data e le 5 V

Da dove arrivano montagne di dati, come si riconoscono, come si trasformano in decisioni e quali regole bisogna rispettare.

DEFINIZIONE

Che cosa sono i big data

Insiemi di dati così **grandi**, **veloci** o **vari** che gli strumenti tradizionali (un foglio di calcolo, un database su un solo computer) non bastano per salvarli ed elaborarli.

Non è solo la dimensione

Conta anche il ritmo con cui arrivano e quanto sono diversi tra loro.

Servono più macchine

I dati si dividono su molti server che lavorano in parallelo.

Lo scopo è decidere

Si raccolgono per scoprire tendenze, prevedere, migliorare un servizio.

LE FONTI

Da dove arrivano i dati

Sensori e IoT

Contatori, termostati, auto, macchinari, smartwatch: misure continue, spesso ogni secondo.

Social

Post, commenti, foto, video, "mi piace": tanto testo e tante immagini, scritte da persone.

Transazioni

Pagamenti, acquisti online, biglietti, prenotazioni: dati ordinati con importi e date.

Log

I "diari" di server, app e siti: ogni accesso, clic o errore lascia una riga.

Molti dati sono prodotti **dalle macchine**, non dalle persone: un sensore non si stanca mai di misurare.

UNITÀ DI MISURA

Dal byte all'exabyte: ogni passo vale mille volte

Unità	Byte	Ordine di grandezza, per farsi un'idea
byte · B	1	un carattere di testo semplice
kilobyte · kB	10^3	una pagina di solo testo: pochi kB
megabyte · MB	10^6	una foto dello smartphone: alcuni MB
gigabyte · GB	10^9	un film in alta definizione: alcuni GB
terabyte · TB	10^{12}	il disco di un normale PC: circa 1 TB
petabyte · PB	10^{15}	gli archivi annuali di un grande laboratorio come il CERN
exabyte · EB	10^{18}	il traffico Internet mondiale si misura in EB al mese

Esistono anche le unità binarie (KiB, MiB, GiB…) in cui ogni passo vale 1024: le usa spesso il sistema operativo.

AL COMPUTER · 15 minuti

Stima: quanti dati produce la classe?

	A	B	C	D
1	Voce	Quanti	MB	MB/giorno
2	Foto	10	3	=B2*C2
3	Video	2	100	
4	Vocali	10	0,5	
5	Studente			=SOMMA(D2:D4)

B = quanti al giorno per studente, C = MB ciascuno (video da 1 minuto). Sono **stime** da discutere, non dati ufficiali.

1. Apri **Calc** e ricopia il foglio; trascina la formula di D2 fino a D4.
2. In D6 calcola il totale per **25 studenti**, in D7 quello di un anno in GB: `=D6*365/1000`.
3. Salva come `stima-dati-classe.ods`.

Controllo: D5 = 235 MB; in un anno la classe produce circa 2144 GB, cioè circa 2,1 TB.

TIPI DI DATI

Strutturati, semi-strutturati, non strutturati

Strutturati

Righe e colonne con uno **schema fisso**.

Tabelle di un database, un foglio di calcolo, gli ordini di un negozio online.

Semi-strutturati

Hanno **etichette** ma non uno schema rigido.

```
{"utente": "anna",
 "tag": ["bici"]}
```

JSON, XML, email, file di log.

Non strutturati

Nessuna organizzazione interna **leggibile dalla macchina**.

Foto, video, audio, testi liberi, documenti scansionati.

La maggior parte dei dati prodotti oggi è non strutturata: è anche la più difficile da analizzare.

LE 5 V

Cinque domande per capire un dataset

Le prime tre V descrivono i dati, le ultime due dicono se ci si può fidare e se ne vale la pena.

V

Volume

Quanti?

V

Velocità

Quanto in fretta?

V

Varietà

Di che tipo?

V

Veridicità

Sono affidabili?

V

Valore

A che cosa servono?

LE PRIME TRE V

Volume, Velocità, Varietà

Volume

La quantità: da terabyte a petabyte e oltre.

Esempio: gli archivi degli esperimenti di fisica delle particelle crescono di petabyte ogni anno.

Velocità

Il ritmo con cui arrivano e la fretta di usarli.

Esempio: un pagamento con carta va controllato contro le frodi prima di essere autorizzato, in pochi istanti.

Varietà

Formati e fonti diversi da mettere insieme.

Esempio: in un ospedale ci sono esami in tabella, referti scritti, immagini radiologiche, segnali dei monitor.

Volume e velocità insieme: una rete di sensori che misura **ogni secondo** non si ferma mai, quindi i dati crescono senza sosta.

LE ULTIME DUE V

Veridicità e Valore

Veridicità

Quanto i dati sono corretti e affidabili.

- Un sensore guasto che segna 999 °C.
- Righe duplicate, celle vuote, unità diverse.
- Recensioni false, profili automatici.

Valore

I dati servono solo se portano a una decisione.

- Un'azienda di trasporti vede dove i bus sono pieni e aggiunge corse.
- Una fabbrica capisce quando un macchinario sta per guastarsi.

Dati sbagliati portano a decisioni sbagliate: pulire i dati è spesso il lavoro più lungo.

AL COMPUTER · 15 minuti

Classifica i dataset: tipo e V principale

#	Dataset
1	Temperatura e umidità inviate ogni secondo da migliaia di sensori di una città
2	Anni di video delle telecamere di un museo
3	Recensioni di ristoranti: stelle, testo libero e foto
4	Ordini di un negozio online: cliente, prodotto, prezzo, data
5	Log di un'app salvati in formato JSON
6	Tracce GPS di un'app per la corsa, con salti di centinaia di metri in galleria

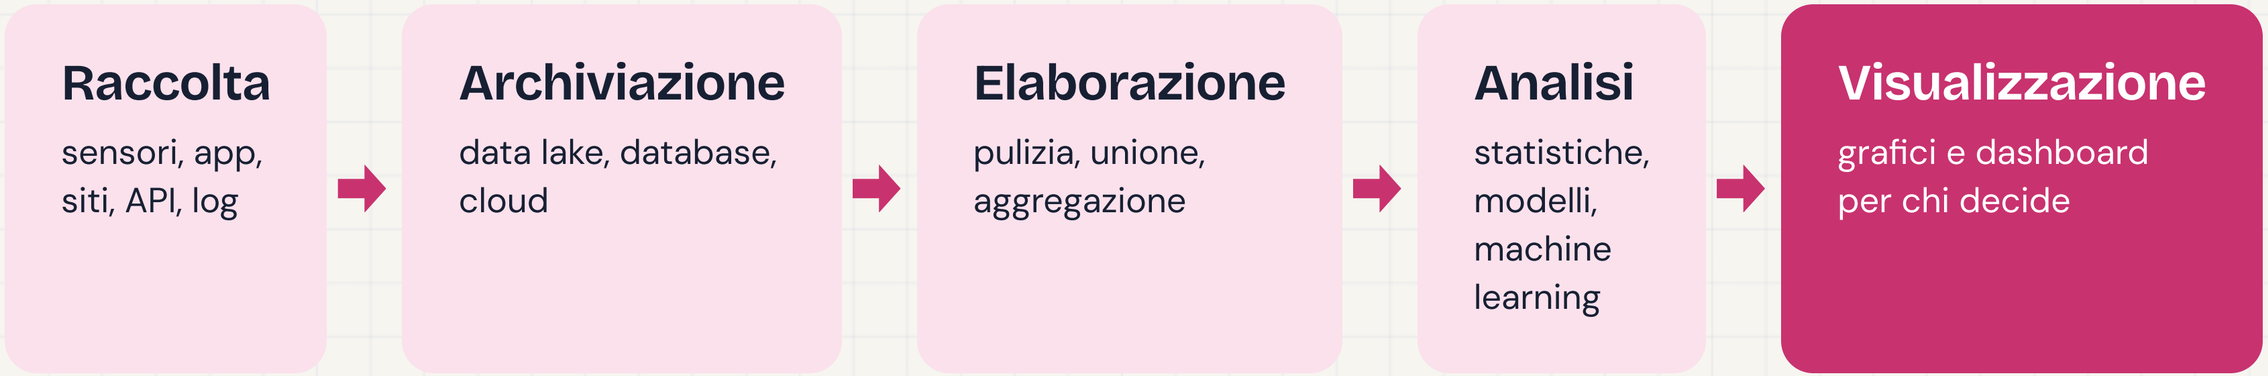
In **Calc** crea le colonne **Dataset · Tipo · V principale · Motivazione**. Salva come `classificazione.ods`.

Una V sola non basta? Scegli la più importante e cita l'altra nella motivazione.

Controllo: il 2 è non strutturato, il 4 è strutturato; il 6 è il caso tipico di Veridicità.

LA PIPELINE

Dal dato grezzo alla decisione



Ogni fase prepara la successiva. Un errore nella raccolta arriva fino al grafico finale, se nessuno lo ferma nell'elaborazione.

> Oggi le proviamo in piccolo: la **stima** (raccolta e archiviazione), la **pulizia** in Calc (elaborazione), il **grafico** (visualizzazione).

AL COMPUTER · 20 minuti

Pulisci i dati del sensore (veridicità)

	A	B
1	Ora	Temp °C
2	08:00	20,5
3	09:00	21
4	09:00	21
5	10:00	21,5 °C
6	11:00	999
7	12:00	22,5
8	13:00	
9	14:00	23

1. Ricopia i dati in **Calc**; in B11 scrivi `=MEDIA(B2:B9)` e annota il risultato.
2. Copia i dati in un secondo foglio chiamato **Pulito**. Scrivi **Controllo** in C1, in C2 la formula sotto, e trascinala fino a C9.
3. Elimina la riga doppia, scrivi 21,5 come numero, svuota i valori impossibili: **non inventarli**. Salva come `sensore-aula.ods`.

```
=SE(VAL.NUMERO(B2);SE(B2>50;"fuori scala";"ok");"da controllare")
```

Controllo: prima della pulizia la media è 184,5 °C; dopo è 21,7 °C.

GLI STRUMENTI

Come si gestiscono davvero i big data

Data lake

Un grande archivio dove si versano i dati **grezzi**, in qualunque formato, per decidere dopo come usarli.

Il data warehouse invece contiene dati già puliti e strutturati per le analisi.

Hadoop e Spark

Hadoop divide file enormi su molti computer e li elabora in parallelo. **Spark** lavora soprattutto in memoria ed è più veloce in molti casi.

Entrambi sono progetti open source della Apache Software Foundation.

Database NoSQL

Non usano solo tabelle: si adattano a dati vari e a carichi enormi.

- **documenti**
- **chiave-valore**
- **colonne**
- **grafi**

L'idea comune: invece di un computer sempre più potente, **tanti computer normali** che lavorano insieme.

AL COMPUTER · 15 minuti

Dal foglio pulito al grafico

1. Nel foglio **Pulito** di `sensore-aula.ods` seleziona le colonne Ora e Temp (A1:B8).
2. Usa **Inserisci ▸ Grafico** e scegli il tipo **Linee** (punti e linee).
3. Aggiungi il titolo "Temperatura in aula" e i nomi degli assi: Ora, °C.
4. Fai lo stesso grafico con i dati del primo foglio, quelli sporchi, e mettili a confronto.

Domanda

Che cosa succede al grafico sporco? Quale dei due mostreresti a chi deve decidere?

Controllo: nel grafico pulito la linea sale da 20,5 a 23 °C con due buchi; in quello sporco il 999 schiaccia tutto il resto.

PRIVACY

Dati personali e GDPR

Dato personale: qualunque informazione su una persona identificata o identificabile, anche una posizione GPS o un indirizzo IP.

- **Base giuridica**, per esempio il consenso.
- **Finalità** dichiarata: i dati si usano solo per quello scopo.
- **Minimizzazione**: solo i dati che servono.
- **Conservazione** limitata nel tempo e **sicurezza**.

I tuoi diritti

Accesso, rettifica, cancellazione ("diritto all'oblio"), portabilità, opposizione.

Il **GDPR** (Regolamento UE 2016/679) si applica dal 25 maggio 2018. Le sanzioni arrivano fino a 20 milioni di euro o al 4% del fatturato mondiale annuo.

RIPASSO

Che cosa portarsi a casa

1

Fonti e tipi

Sensori, social, transazioni, log. Dati strutturati, semi-strutturati, non strutturati.

2

Le 5 V

Volume, Velocità, Varietà, Veridicità, Valore. Unità fino a PB ed EB.

3

Pipeline e regole

Raccolta, archiviazione, elaborazione, analisi, visualizzazione. Sempre nel rispetto del GDPR.

Più dati non vuol dire più verità: servono dati **puliti**, **utili** e raccolti **con il permesso**.