UNITÀ 1 · CODIFICA DELLE INFORMAZIONI

Dalle lettere ai numeri

Quando scrivi «Però costa 5 €» il computer salva solo numeri. Quali, e chi li ha decisi? ASCII, Unicode, UTF-8 ed emoji.

ASCII Unicode UTF-8

PER COMINCIARE

Quante emoji mandi in un giorno, più o meno?

SONDAGGIO

- **A** Quasi nessuna
- **B** Da 1 a 20
- **C** Da 20 a 100
- **D** Più di 100

L'IDEA

Una codifica è una tabella condivisa



- Il numero di un carattere si chiama **codice**
- Chi scrive e chi legge devono usare la **stessa tabella**, altrimenti escono simboli strani
- L'idea è antica: il codice Morse (1838) e il codice Baudot dei telescriventi (1870)

1963

ASCII: 7 bit, 128 caratteri

Codici	Che cosa contengono	Esempi
0–31	caratteri di controllo	a capo (10), tab (9)
32	lo spazio	" "
48–57	le cifre	'0' = 48, '9' = 57
65–90	maiuscole	'A' = 65, 'Z' = 90
97–122	minuscole	'a' = 97, 'z' = 122

Il trucco dei 32

'A' = `100 0001`

'a' = `110 0001`

Maiuscola e minuscola differiscono di 32: un solo bit.

ASCII = American Standard Code for Information Interchange. Niente accenti, niente €: era pensato per l'inglese.

QUIZ A TRABOCCHETTO

Il computer ordina le parole per codice. Quale viene per prima?

QUIZ

A zebra

B Zebra

C albero

D Albero

AL COMPUTER · 15 minuti

Codici ASCII nella console del browser

Premi **F12**, scheda **Console**. Prova una riga alla volta:

```
"A".charCodeAt(0)
"TPSI".split("").map(c => c.charCodeAt(0))
String.fromCharCode(66, 114, 97, 118, 105)
"a".charCodeAt(0) - "A".charCodeAt(0)
```

Poi trova i codici del tuo nome e scrivi un messaggio segreto per un compagno. Salva tutto in **ascii-nome.txt**.

Controllo: 65 · [84, 80, 83, 73] · "Bravi" · 32

IL CAOS DEGLI ANNI OTTANTA E NOVANTA

8 bit, mille tabelle diverse

Con l'ottavo bit i codici da 128 a 255 diventano liberi. Ogni paese li riempie a modo suo: **ISO 8859-1** per l'Europa occidentale, Windows-1252, tabelle per il greco, il cirillico…

In ISO 8859-1 la «è» ha codice 232. In una tabella cirillica, 232 è una lettera russa.

Il mojibake

Testo scritto con una tabella e letto con un'altra:

caffÃ¨

È «caffè» salvato in UTF-8 e aperto come ISO 8859-1.

UNA TABELLA PER TUTTO IL MONDO

Unicode: un numero per ogni carattere

A

U+0041

65, come in ASCII

è

U+00E8

232

€

U+20AC

8364

ω

U+03C9

omega greca

- Il numero si chiama **code point** e si scrive U+ seguito dall'esadecimale
- Spazio per 1 114 112 code point; oggi ne sono assegnati oltre 150 000
- Più di 160 sistemi di scrittura, simboli matematici, musicali… ed emoji

MENTI CHE CI HANNO PRECEDUTO

Dove nasce Unicode

> **Unicode vuole rispondere al bisogno di una codifica del testo mondiale che funzioni e sia affidabile.**

Joseph D. Becker, ingegnere della Xerox, nella proposta "Unicode 88", 1988



DA CODE POINT A BYTE

UTF-8: da 1 a 4 byte, secondo il bisogno

Code point	Byte	Schema dei bit	Esempi
`U+0000 – U+007F`	1	`0xxxxxxx`	A, 7, spazio: identici ad ASCII
`U+0080 – U+07FF`	2	`110xxxxx 10xxxxxx`	è, à, ω, lettere cirilliche
`U+0800 – U+FFFF`	3	`1110xxxx 10xxxxxx 10xxxxxx`	€, cinese, giapponese
`U+10000 – U+10FFFF`	4	`11110xxx 10xxxxxx ×3`	emoji, scritture antiche

> Il primo byte dice quanti byte seguono; quelli dopo iniziano sempre con `10`. Un testo ASCII è già un testo UTF-8 valido.

A MANO

La «è» diventa C3 A8

1. Code point: U+00E8 = 232, sta tra U+0080 e U+07FF → servono **2 byte**
2. In binario su 11 bit: `000 1110 1000`
3. Dividi: i primi 5 bit `00011`, gli ultimi 6 bit `101000`
4. Inseriscili nello schema `110xxxxx 10xxxxxx`

Risultato

`11000011 10101000 = 1100 0011 1010 1000 = C3 A8`

AL COMPUTER · 20 minuti

Guarda i byte di un file di testo

1. Apri **Blocco note** e scrivi esattamente: **Però costa 5 €**
2. Salva come **caratteri.txt**, codifica **UTF-8**.
3. Tasto destro sul file › **Proprietà**: annota la dimensione in byte.
4. Apri **hexed.it**, trascina il file nella pagina e cerca i byte di ò e di €.
5. Annota in **caratteri.txt**, sotto la frase: caratteri, byte e i codici trovati.

Controllo: 14 caratteri ma **17 byte**. ò = `C3 B2`, € = `E2 82 AC`, tutti gli altri un byte solo (P = `50`).

METTITI ALLA PROVA

Quanti byte occupa in UTF-8 la parola «città»?

QUIZ

A 5

B 6

C 10

D 7

LE EMOJI

Un'emoji può essere fatta di più caratteri

Emoji	Code point	Byte UTF-8
pollice in su	`U+1F44D`	`4 · F0 9F 91 8D`
pollice in su, pelle media	`U+1F44D U+1F3FD`	8
famiglia uomo, donna, bambina	`U+1F468 U+200D U+1F469 U+200D U+1F467`	18

- Il colore della pelle è un **modificatore**: un secondo code point subito dopo
- Le famiglie sono emoji unite dal carattere invisibile **ZWJ** (U+200D, "zero width joiner")
- Il disegno lo decide il font del sistema: lo stesso code point è diverso su Android e iPhone

AL COMPUTER · 10 minuti

Quanto è lunga un'emoji?

Nella console (F12). Per scrivere un'emoji premi **Windows + .** (punto) e scegli il pollice in su.

```
"ciao".length
"👍".length
[..."👍"].length
"👍".codePointAt(0).toString(16)
new TextEncoder().encode("👍").length
```

Aggiungi i risultati a **caratteri.txt**.

Controllo: 4 · **2** (unità UTF-16, come i char di Java) · 1 (un code point) · "1f44d" · 4 byte in UTF-8

PUZZLE

Abbina ogni carattere al suo codice

A	---	97 (U+0061)
a	---	65 (U+0041)
0 (la cifra)	---	8364 (U+20AC)
spazio	---	232 (U+00E8)
è	---	32 (U+0020)
€	---	48 (U+0030)

OGGI

Come leggono il testo le intelligenze artificiali





SFIDA A SQUADRE

Il codice è nascosto nella tabella ASCII



Un messaggio è arrivato come quattro byte in decimale:

52 56 49 55

Sono caratteri ASCII. Decodificali: quello è il codice del lucchetto.

codice

BIGLIETTO D'USCITA

Completa prima di uscire

Il codice ASCII usa _____ bit e la lettera A vale _____.

In Unicode il numero di un carattere si chiama code _____.

In UTF-8 la «è» occupa _____ byte, l'euro ne occupa _____.

I modelli linguistici dividono il testo in _____.

⏱ 3:00

RIEPILOGO

Cosa portiamo a casa

- Codifica = tabella condivisa carattere ↔ numero
- ASCII: 7 bit, 128 caratteri, A = 65, a = 97
- Tabelle diverse a 8 bit → mojibake
- Unicode: un code point per ogni carattere
- UTF-8: da 1 a 4 byte, compatibile con ASCII
- Caratteri, code point e byte sono tre conti diversi

Hai una domanda su una slide? Usa il pulsante **? Domande** in basso: la vedrà il docente e tutta la classe.